

UNIVERSIDADE FEDERAL DO PARANÁ

Carlos Ronchi

Lista 3 - CM116

Lista de exercícios para a disciplina de tópicos em matemática aplicada I.

Professor Dr. Geovani Grapiglia.

Curitiba
Junho de 2017

Solução. (Exercício 1)

Para este exercício vamos usar os seguintes lemas.

LEMA 0.1. *Seja $A \in \mathbb{R}^{m \times n}$, então $\text{Ker}(A^T A) = \text{Ker}(A)$.*

Demonstração. Seja $x \in \text{Ker}(A)$, então $A^T A x = A^T 0 = 0$. Portanto, $x \in \text{Ker}(A^T A)$.

Agora, seja $x \in \text{Ker}(A^T A)$, então $A^T A x = 0$. Multiplicando por x^T em ambos os lados, temos que

$$\|Ax\| = 0.$$

Portanto, $Ax = 0$ e assim $x \in \text{Ker}(A)$. Concluimos então que $\text{Ker}(A^T A) = \text{Ker}(A)$. \square

LEMA 0.2. *Seja $A \in \mathbb{R}^{m \times n}$, então $A^T A$ possui autovalores não-negativos.*

Demonstração. Seja v um autovetor associado a λ da matriz $A^T A$, então

$$A^T A v = \lambda v \rightarrow v^T A^T A v = \lambda v^T v.$$

Como $A^T A$ é uma matriz semi definida positiva, temos que

$$\lambda v^T v \geq 0.$$

Além disso, como v é um autovetor, $v^T v > 0$, portanto,

$$\lambda \geq 0.$$

\square

Vamos agora provar o SVD. Seja $A \in \mathbb{R}^{m \times n}$ uma matriz qualquer e suponha que $m \geq n$. Seja a matriz $A^T A \in \mathbb{R}^{n \times n}$ e sejam x_1, \dots, x_n autovetores ortonormais e $\lambda_1, \dots, \lambda_n$ os seus respectivos autovalores. Vamos ordenar os autovalores de forma que $\lambda_1 \geq \dots \geq \lambda_n$. E seja r tal que

$$\lambda_1 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_n.$$

Defina agora os vetores

$$q_i = \frac{1}{\sqrt{\lambda_i}} A x_i, \quad \text{para } i \leq r,$$

e chame de $\sigma_i = \sqrt{\lambda_i}$, para todo $i = 1, \dots, n$.

Observe que $q_i^T q_j = 0$ para todo $i \neq j$ e $q_i^T q_i = 1$. Portanto, vamos completar $\{q_1, \dots, q_r\}$ de forma a obter uma base $\{q_1, \dots, q_r, q_{r+1}, \dots, q_m\}$ de \mathbb{R}^m . Sejam agora as matrizes

$$U = \begin{pmatrix} | & & | \\ q_1 & \dots & q_m \\ | & & | \end{pmatrix}, \quad V = \begin{pmatrix} | & & | \\ x_1 & \dots & x_n \\ | & & | \end{pmatrix}.$$

Note que $x_j \in \text{Ker}(A^T A)$ para $j > r$, pois o autovalor associado a x_j é 0. Pelo Lema 0.1, $Ax_j = 0$. Portanto,

$$(U^T A V)_{ij} = q_i^T A x_j = \begin{cases} \frac{1}{\sigma_i} x_i^T A^T A x_j & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases} = \begin{cases} \sigma_i \delta_{ij} & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases},$$

pois

$$\frac{1}{\sigma_i} x_i^T A^T A x_j = \frac{\lambda_j}{\sigma_i} x_i^T x_j = \sigma_i \delta_{ij}.$$

Portanto, $U^T A V$ é dada por

$$\begin{matrix} & \overbrace{\hspace{1cm}}^n \\ \text{n} \left\{ \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n \\ 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 \end{bmatrix} \right\} \begin{matrix} \\ \\ \\ \\ \end{matrix} \end{matrix} \begin{matrix} \\ \\ \\ \\ \end{matrix} \overbrace{\hspace{1cm}}^{m-n}$$

Denotando por Σ a matriz acima, temos que

$$A = U\Sigma V^T$$

Seja agora $m < n$. Considere a matriz simétrica AA^T . Do mesmo modo que a anterior, temos que seus autovalores são todos não negativos. Sejam v_1, \dots, v_m os autovalores ortonormais associados a $\lambda_1, \dots, \lambda_m$ autovalores. Ordene $\lambda_1 \geq \dots \geq \lambda_m$. Denote por $\sigma_i = \sqrt{\lambda_i}$ para todo $i = 1, \dots, m$. Seja r tal que

$$\lambda_1 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_m.$$

Para $i = 1, \dots, r$, denote por

$$q_i = \frac{1}{\sigma_i} A^T v_i.$$

Note que os q_i 's são ortonormais. Completando a base e utilizando o processo de ortogonalização de Gram-Schmidt, temos uma base $\{q_1, \dots, q_r, q_{r+1}, \dots, q_n\}$ ortonormal de \mathbb{R}^n . Sejam agora as matrizes

$$U = \begin{pmatrix} | & & | \\ v_1 & \dots & v_m \\ | & & | \end{pmatrix}, \quad V = \begin{pmatrix} | & & | \\ q_1 & \dots & q_n \\ | & & | \end{pmatrix}.$$

Além disso, de modo análogo ao Lema 0.1, temos que $\text{Ker}(AA^T) = \text{Ker}(A^T)$, basta substituir A por A^T . Portanto,

$$(U^T AV)_{ij} = v_i^T A q_j = \begin{cases} \frac{1}{\sigma_i} v_i^T A A^T v_j & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases} = \begin{cases} \sigma_j \delta_{ij} & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases},$$

pois $v_i \in \text{Ker}(A^T)$ e

$$\frac{1}{\sigma_j} v_i^T A A^T v_j = \frac{\lambda_i}{\sigma_j} v_i^T v_j = \sigma_j \delta_{ij}.$$

Portanto, a matriz $U^T AV$ é dada por

$$\begin{matrix} & \overbrace{\hspace{1.5cm}}^m & \overbrace{\hspace{1.5cm}}^{n-m} \\ m \left\{ \begin{bmatrix} \sigma_1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & 0 & \dots & 0 \\ 0 & 0 & \dots & \sigma_m & 0 & \dots & 0 \end{bmatrix} \right. \end{matrix}$$

□

Solução. (Exercício 2)

Suponha $m < n$, então

$$\begin{aligned} Ax &= U\Sigma V^T = \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & 0 \\ & & \ddots & 0 \\ & & & \sigma_m & 0 \end{pmatrix} \begin{pmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_n^T & - \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \\ &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 v_1^T x \\ \vdots \\ \sigma_m v_m^T x \end{pmatrix} \end{aligned}$$

Seja agora $x = v_i$, então

$$\begin{aligned}
 Av_i &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 v_1^T v_i \\ \vdots \\ \sigma_m v_m^T v_i \end{pmatrix} \\
 &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ \vdots \\ \sigma_i \\ 0 \\ \vdots \\ 0 \end{pmatrix} \\
 &= \begin{pmatrix} \sigma_i u_{i1} \\ \sigma_i u_{i2} \\ \vdots \\ \sigma_i u_{ii} \\ \vdots \\ \sigma_i u_{im} \end{pmatrix} = \sigma_i u_i
 \end{aligned}$$

Já para $A^T u_i$, temos que

$$\begin{aligned}
 A^T x &= V \Sigma^T U^T = \begin{pmatrix} | & & | \\ v_1 & \dots & v_n \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ 0 & \dots & 0 & \sigma_m \\ & & & 0 \end{pmatrix} \begin{pmatrix} - & u_1^T & - \\ & \vdots & \\ - & u_m^T & - \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} \\
 &= \begin{pmatrix} | & & | \\ v_1 & \dots & v_n \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 u_1^T x \\ \vdots \\ \sigma_m u_m^T x \\ 0 \\ \vdots \\ 0 \end{pmatrix}
 \end{aligned}$$

Portanto, para $x = u_i$

$$A^T u_i = \sigma_i v_i.$$

Para calcular os valores de σ_i , u_i e v_i ,

$$A^T A v_i = \sigma_i A^T u_i = \sigma_i^2 v_i.$$

Logo, v_i é o autovetor de $A^T A$ associado ao autovalor σ_i^2 da matriz $A^T A$. E

$$A A^T u_i = \sigma_i A v_i = \sigma_i^2 u_i.$$

Logo, u_i é o autovetor de $A A^T$ associado ao autovalor σ_i^2 da matriz $A A^T$. Isto pode ser visto também através da demonstração do SVD pelo exercício 1. \square

Solução. (Exercício 3)

(a) De fato, como $A = U \Sigma V^T$, e como U, V^T são matrizes ortogonais, temos que $\text{posto}(U \Sigma V^T) =$

posto(Σ). E como $\text{posto}(\Sigma) = r$, já que

$$\Sigma = \begin{pmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \\ & & & & & & 0 \\ & & & & & & & 0 \\ 0 & & & & & & & & 0 \end{pmatrix}$$

$$\Rightarrow \text{posto}(A) = \text{posto}(\Sigma) = r.$$

(b) Seja $x \in \mathbb{R}^n$, então

$$x = b_1 v_1 + \dots b_n v_n,$$

onde v_1, \dots, v_n são os vetores singulares à direita da decomposição SVD da matriz A. Então, pelo exercício 2

$$\begin{aligned} Ax &= A(b_1 v_1 + \dots b_n v_n) = b_1 \sigma_1 u_1 + \dots b_r \sigma_r u_r \\ \Rightarrow \text{Im}(A) &\in \text{span}\{u_1, \dots, u_r\} \end{aligned}$$

Seja $x \in \text{span}\{u_1, \dots, u_r\}$. Pelo exercício 2, $u_i = \frac{1}{\sigma_i} A v_i$, portanto, $x \in \text{Im}(A)$.

$$\text{Im}(A) = \text{span}\{u_1, \dots, u_r\}.$$

(c) Seja $x \in \text{Ker}(A)$. Como $x \in \mathbb{R}^n$, $x = b_1 v_1 + \dots b_n v_n$.

$$A(b_1 v_1 + \dots + b_n v_n) = 0 \Rightarrow b_1 \sigma_1 u_1 + \dots + b_r \sigma_r u_r = 0$$

Como os vetores u_1, \dots, u_m formam uma base para \mathbb{R}^m e $\sigma_1, \dots, \sigma_r \neq 0$, temos que

$$b_1 = \dots = b_r = 0.$$

Portanto, $x \in \text{span}\{v_{r+1}, \dots, v_n\}$. Do mesmo modo, temos que $A v_i = \sigma_i u_i$. Se $i > r$, então $\sigma_i = 0$.

$$A v_i = 0 \Rightarrow v_i \in \text{Ker}(A) \Rightarrow \text{Ker}(A) = \text{span}\{v_{r+1}, \dots, v_n\}.$$

(d) De fato, note que pelos exercícios anteriores, se $m < n$, então

$$\begin{aligned} A &= U \Sigma V^T = \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & 0 \\ & & \ddots & 0 \\ & & & \sigma_m & 0 \end{pmatrix} \begin{pmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_n^T & - \end{pmatrix} \\ &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 v_1^T x \\ \vdots \\ \sigma_m v_m^T x \end{pmatrix} \\ &= \sum_{i=1}^m \sigma_i u_i v_i^T = \sum_{i=1}^r \sigma_i u_i v_i^T \end{aligned}$$

□

Solução. (Exercício 4)

- (a) Esta é a norma de Frobenius de uma matriz A , dada por

$$\|A\|_F^2 = \text{tr}(AA^T),$$

onde tr é o operador traço. Além disso, se U for uma matriz ortogonal, então

$$\|UA\|_F^2 = \text{tr}(UAA^T U^T) = \text{tr}(AA^T U^T U) = \text{tr}(AA^T) = \|A\|_F^2.$$

Ainda mais, isto vale para multiplicação à direita, ou seja

$$\|AU\|_F^2 = \text{tr}(AUU^T A^T) = \text{tr}(AA^T) = \|A\|_F^2.$$

Portanto,

$$\|A\|_F^2 = \|U\Sigma V^T\|_F^2 = \|\Sigma\|_F^2 = \sigma_1^2 + \dots + \sigma_p^2,$$

$$p = \min\{m, n\}.$$

- (b) Note que se x é um vetor cuja norma é igual a um e V é uma matriz ortogonal, então $\|Vx\| = \|x\| = 1$. Portanto,

$$\begin{aligned} \|A\|_2 &= \sup_{\|x\|=1} \|Ax\| = \sup_{\|x\|=1} \|U\Sigma V^T x\| \\ &= \sup_{\|x\|=1} \|\Sigma V^T x\| = \sup_{\|V^T x\|=1} \|\Sigma V^T x\| = \sup_{\|y\|=1} \|\Sigma y\| \\ &= \|\Sigma\|_2 \end{aligned}$$

Suponha que $m < n$, então

$$\Sigma = \begin{pmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & 0 \\ & & \ddots & 0 \\ & & & \sigma_m & 0 \end{pmatrix}$$

Logo,

$$\|\Sigma\|_2 = \sup_{\|x\|=1} \|\Sigma x\| = \sup_{\|x\|=1} \left| \sqrt{\sigma_1^2 x_1^2 + \dots + \sigma_m^2 x_m^2} \right| \leq \sup_{\|x\|=1} \sigma_1 \|x\| = \sigma_1,$$

já que $\sigma_1 > 0$. Agora seja $x = (1, 0, \dots, 0) \in \mathbb{R}^n$. Então, $\|x\|_2 = 1$. Portanto, $\|\Sigma x\|_2 = \sigma_1$. Ou seja, $\|\Sigma\|_2 \geq \sigma_1$.

$$\|A\|_2 = \|\Sigma\|_F = \sigma_1.$$

de modo análogo temos que para $m \geq n$.

- (c) Seja $m \geq n$. Então,

$$\Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

Assim,

$$\begin{aligned} \min_{x \neq 0} \frac{\|Ax\|}{\|x\|} &= \min_{x \neq 0} \|\Sigma x\| / \|x\| \\ &= \min_{x \neq 0} \frac{\left| \sqrt{\sigma_1^2 x_1^2 + \dots + \sigma_n^2 x_n^2} \right|}{\|x\|} \\ &\geq \sigma_n \min_{x \neq 0} \frac{\|x\|}{\|x\|} = \sigma_n. \end{aligned}$$

Por outro lado, seja $x = (0, 0, \dots, 0, 1) \in \mathbb{R}^m$, então

$$\begin{aligned} \min_{y \neq 0} \frac{\|Ay\|_2}{\|y\|_2} &\leq \frac{\|\Sigma x\|_2}{\|x\|_2} = \sigma_n. \\ \Rightarrow \min_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} &= \sigma_n. \end{aligned}$$

□

Solução. (Exercício 5)

Note que $\|A - A_k\|_2 = \sigma_{k+1}$, pois

$$\|A - A_k\|_2 = \left\| \sum_{j=k+1}^n \sigma_j u_j v_j^T \right\| = \sigma_{k+1}$$

pelo exercício 4-b. Portanto, resta mostrar que

$$\min_{\text{posto}(B)=k} \|A - B\|_2 = \|A - A_k\|.$$

Como $\text{posto}(A_k) = k$, já que $k < r$, temos que

$$\min_{\text{posto}(B)=k} \|A - B\|_2 \leq \|A - A_k\|.$$

Resta mostrar que

$$\min_{\text{posto}(B)=k} \|A - B\|_2 \geq \|A - A_k\|.$$

Seja $U\Sigma V^T$ a decomposição SVD da matriz A . Seja B uma matriz de posto igual a k . Como $k < r$, temos pelo teorema do núcleo e da imagem que $\dim(\text{Ker}(B)) = n - k$. Além disso, restrinja a matriz V para V_k , sendo V_k a matriz das primeiras $k+1$ colunas de V , portanto, $\dim(V_k) = k+1$. Logo,

$$\dim(\text{Ker}(B)) + \dim(V_k) = n - k + k + 1 = n + 1.$$

Como a soma das dimensões é maior que n e ambos espaços estão contidos em \mathbb{R}^n , temos que

$$\text{Ker}(B) \cap V_k \neq \emptyset.$$

Tome $x \in \text{Ker}(B) \cap V_k$, tal que $\|x\|_2 = 1$. Então

$$\|A - B\|_2 \geq \|Ax - Bx\|_2 = \|A_{k+1}x\|_2.$$

Como $x \in V_k$, $x = c_1 v_1 + \dots + c_{k+1} v_{k+1}$, então

$$\begin{aligned} A_{k+1}x &= \sum_{i=1}^{k+1} \sigma_i u_i v_i^T x = \sum_{i=1}^{k+1} \sigma_i u_i v_i^T (c_1 v_1 + \dots + c_{k+1} v_{k+1}) \\ &= \sum_{i=1}^{k+1} \sigma_i c_i u_i. \end{aligned}$$

Utilizando o resultado acima, temos que

$$\|A_{k+1}x\|_2^2 = \left\| \sum_{i=1}^{k+1} \sigma_i c_i u_i \right\|_2^2 \geq \sigma_{k+1}^2 \left\| \sum_{i=1}^{k+1} c_i u_i \right\|_2^2.$$

E note que

$$1 = \|x\|_2^2 = \left\langle \sum_i c_i v_i, \sum_j c_j v_j \right\rangle = \sum_{i=1}^{k+1} c_i^2.$$

Mas como os vetores u_1, \dots, u_{k+1} são ortonormais, temos que

$$\left\| \sum_{i=1}^{k+1} c_i u_i \right\|_2^2 = \left\langle \sum_i c_i u_i, \sum_j c_j u_j \right\rangle = \sum_{i=1}^{k+1} c_i^2.$$

Portanto, juntando os resultados acima, temos que

$$\|A - B\|_2 \geq \sigma_{k+1}$$

Assim, obtemos o resultado desejado.

$$\min_{\text{posto}(B)=k} \|A - B\|_2 = \|A - A_k\|_2 = \sigma_{k+1}.$$

□

Solução. (Exercício 6)

Considere a SVD de $A \in \mathbb{R}^{m \times n}$ dada no Exercício 1. Portanto, pelo exercício 4, queremos mostrar que

$$\sigma_1 = \max_{\substack{y \in \mathbb{R}^m \\ x \in \mathbb{R}^n}} \frac{y^T A x}{\|x\|_2 \|y\|_2}.$$

Suponha que a matriz A tenha posto maior ou igual a 1, então $\sigma_1 \neq 0$.

Agora, considere x como o autovetor unitário associado a λ_1 da matriz $A^T A$. Seja agora $y = Ax/\sigma_1$, onde $\sigma_1 = \sqrt{\lambda_1}$. Então

$$\|y\|_2^2 = y^T y = \frac{1}{\sigma_1^2} x^T A^T A x = 1.$$

Logo,

$$y^T A x = \frac{x^T A^T A x}{\sigma_1} = \sigma_1.$$

Acabamos de mostrar que

$$\max_{\substack{y \in \mathbb{R}^m \\ x \in \mathbb{R}^n}} \frac{y^T A x}{\|x\|_2 \|y\|_2} \geq \sigma_1.$$

Vamos mostrar que vale a outra desigualdade agora. Seja $r = \text{posto}(A)$, então

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Como os vetores v_1, \dots, v_n formam uma base de \mathbb{R}^n e u_1, \dots, u_m de \mathbb{R}^m , para todo $x \in \mathbb{R}^n$ e $y \in \mathbb{R}^m$,

$$x = d_1 v_1 + \dots + d_n v_n, \quad y = c_1 u_1 + \dots + c_m u_m.$$

Logo,

$$\begin{aligned} \frac{y^T A x}{\|y\|_2 \|x\|_2} &= \frac{(\sum_{i=1}^m c_i u_i)^T (\sum_{i=1}^r \sigma_i u_i v_i^T) (\sum_{i=1}^n d_i v_i)}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \\ &= \frac{(\sum_{i=1}^m c_i u_i)^T (\sum_{i=1}^r \sigma_i u_i d_i)}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \\ &= \frac{\sum_{i=1}^r \sigma_i c_i d_i}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \\ &\leq \sigma_1 \frac{\sum_{i=1}^r c_i d_i}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \end{aligned} \tag{1}$$

Como $r \leq m, n$, considere os vetores

$$c' = (c_1, \dots, c_r), \quad d' = (d_1, \dots, d_r).$$

Além disso, considere $c = (c_1, \dots, c_m)$ e $d = (d_1, \dots, d_n)$. Então

$$\sum_{i=1}^r c_i^2 \leq \sum_{i=1}^m c_i^2 \Rightarrow \frac{1}{(\sum_{i=1}^r c_i^2)^{\frac{1}{2}}} \geq \frac{1}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}}}.$$

De modo análogo para d e d'

$$\frac{1}{(\sum_{i=1}^r d_i^2)^{\frac{1}{2}}} \geq \frac{1}{(\sum_{i=1}^n d_i^2)^{\frac{1}{2}}}.$$

E pela desigualdade de Cauchy-Schwarz, $|\langle c, d \rangle| \leq \|c\|_2 \|d\|_2$. Portanto,

$$\frac{|\langle c, d \rangle|}{\|c\|_2 \|d\|_2} \leq 1.$$

Substituindo os valores e desigualdades acima na Equação (1), temos que

$$\sigma_1 \frac{\sum_{i=1}^r c_i d_i}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \leq \sigma_1 \frac{\sum_{i=1}^r c_i d_i}{(\sum_{i=1}^r c_i^2)^{\frac{1}{2}} (\sum_{i=1}^r d_i^2)^{\frac{1}{2}}} \leq \sigma_1.$$

Como isto vale para qualquer x e y ,

$$\sigma_1 = \sigma_{\max}(A) = \max_{\substack{y \in \mathbb{R}^m \\ x \in \mathbb{R}^n}} \frac{y^T A x}{\|x\|_2 \|y\|_2}.$$

□

Solução. (Exercício 7)

Vamos usar SVD para provar. Seja $A \in \mathbb{R}^{m \times n}$ uma matriz qualquer, e considere a SVD de A dada no exercício 1. Suponha que $\text{posto}(A) = r$, sendo que $r \leq \min m, n$. Suponha que $n \leq m$, a demonstração a seguir pode ser usada analogamente para o caso $n > m$.

Temos

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Seja agora a sequência de matrizes B_k , onde

$$B_k = \sum_{i=1}^n \left(\sigma_i + \frac{1}{k} \right) u_i v_i^T.$$

Observe que as matrizes B_k tem posto completo, já que $B_k = U \Sigma_k V^T$, onde U, V são matrizes ortogonais e Σ_k possui posto cheio, já que as colunas de Σ_k são linearmente independentes.

$$\Sigma_k = \begin{pmatrix} \sigma_1 + \frac{1}{k} & 0 & \cdots & 0 \\ 0 & \sigma_2 + \frac{1}{k} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n + \frac{1}{k} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix}.$$

Além disso, note que $A - B_k = U(\Sigma - \Sigma_k)V^T$, e portanto,

$$\|A - B_k\|_2 = \|U(\Sigma - \Sigma_k)V^T\|_2 = \|\Sigma - \Sigma_k\|,$$

já que U e V são matrizes ortogonais. Além disso, note que

$$\Sigma - \Sigma_k = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix} - \begin{pmatrix} \sigma_1 + \frac{1}{k} & 0 & \cdots & 0 \\ 0 & \sigma_2 + \frac{1}{k} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n + \frac{1}{k} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix} = \begin{pmatrix} \frac{1}{k} & 0 & \cdots & 0 \\ 0 & \frac{1}{k} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{k} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix}.$$

Sabemos que o valor singular σ_1 de uma matrix A é a raiz quadrada do maior autovalor da matrix $A^T A$. Neste caso, o valor singular σ_1 da matrix $\Sigma - \Sigma_k$ é $\frac{1}{k}$ já que o maior autovalor da matrix $(\Sigma - \Sigma_k)^T(\Sigma - \Sigma_k)$ é $\frac{1}{k^2}$. Pelo exercício 4-b, temos que

$$\|\Sigma - \Sigma_k\|_2 = \sigma_1.$$

Portanto,

$$\|A - B_k\|_2 = \|\Sigma - \Sigma_k\|_2 = \sigma_1 = \frac{1}{k}.$$

Ou seja, para todo $\epsilon > 0$, existe k_0 tal que para todo $k > k_0$,

$$\|A - B_k\|_2 < \epsilon.$$

Assim, mostramos que qualquer matrix em $\mathbb{R}^{m \times n}$ é o limite de uma sequência de matrizes de posto completo. \square

Solução. (Exercício 8)

Seja $\Omega = \{x_1, \dots, x_m\} \subset \mathbb{R}^n$ um conjunto de dados e $k \in (1, m)$ um número natural. O Algoritmo de Lloyd (k -médias) para clusterização consiste em achar centros, ou pontos, de modo que o conjunto de treinamento possa ser separado em k partições, todas disjuntas. Ou seja, o objetivo é encontrar uma partição ótima

$$S = \{S_1, \dots, S_m\}$$

de Ω , isto é, encontrar S_i , chamados de *clusters*, tais que

$$S_i \cap S_j = \emptyset, \quad i \neq j$$

$$\bigcup_{i=1}^k S_i = \Omega.$$

Em termos de minimização, queremos resolver o seguinte problema de minimização.

$$\min_{\substack{S \\ \text{partição de } \Omega}} \sum_{i=1}^k \sum_{x_j \in S_i} \|x_j - \mu_i\|_2^2, \quad \text{onde } \mu_i = \frac{1}{|S_i|} \sum_{x_j \in S_i} x_j.$$

Então, o Algoritmo de Lloyd é dado a seguir. \square

Solução. (Exercício 9)

Seja um banco de dados $\{I_1, \dots, I_m\}$, onde cada I_i é uma matrix de imagens em escala cinza. Temos m imagens, de tamanho $n \times n$, divididas em p classes, onde cada classe representa a face de uma pessoa. Para cada matrix I_j , denote por Φ_j o vetor de concatenação das matrizes. Seja A a matrix abaixo.

$$A = \begin{pmatrix} | & | & \cdots & | \\ \Phi_1 & \Phi_2 & \cdots & \Phi_m \\ | & | & & | \end{pmatrix} \in \mathbb{R}^{n^2 \times m}.$$

Para classificar uma nova imagem $I_{new} = \Phi_{new}$, calculamos a projeção ortogonal no espaço gerado pelas colunas da matrix A , assim podemos dizer de qual vetor coluna da matrix A , a imagem Φ_{new} está mais perto, e esta será a sua classe. Portanto, o procedimento é dado no Algoritmo abaixo. \square

Algoritmo 1 Algoritmo de Lloyd

- 1: Escolha k pontos $m_1^{(1)}, \dots, m_k^{(1)}$ em Ω , os quais serão usados como "médias iniciais". Defina $t = 1$.
- 2: Para cada $j = 1, \dots, m$, encontre

$$i \in \operatorname{argmin}_{l=1, \dots, k} \|x_j - m_l^{(t)}\|$$

e associe x_j ao cluster S_i .

- 3: Se $t > 1$ e $S^t = S^{t-1}$, pare.
- 4: (Atualização das médias) Para cada $i = 1, \dots, k$, defina

$$m_i^{t+1} = \frac{1}{|S_i|} \sum_{x_j \in S_i^{(t)}} x_j$$

- 5: Defina $t = t + 1$ e volte para o passo 2.
-

Algoritmo 2 Auto-faces para reconhecimento facial

- 1: Calcule a projeção ortogonal $\hat{\Phi}_{new}$ de Φ_{new} sobre o subespaço gerado por Φ_1, \dots, Φ_m .

$$\hat{\Phi}_{new} = A(A^T A)^{-1} \Phi_{new}$$

- 2: Calcule

$$j = \operatorname{argmin}_{i=1, \dots, m} \|\hat{\Phi}_{new} - \Phi_i\|$$

- 3: Dizemos então que a face em I_{new} é a face da pessoa em I_j .
-