

**UNIVERSIDADE FEDERAL DO PARANÁ**

**Carlos Ronchi**

Lista 3 - CM116

Lista de exercícios para a disciplina de tópicos em matemática aplicada I.

Professor Dr. Geovani Grapiglia.

**Curitiba**  
**Junho de 2017**

*Solução.* (Exercício 1)

Para este exercício vamos usar os seguintes lemas.

**LEMA 0.1.** *Seja  $A \in \mathbb{R}^{m \times n}$ , então  $\text{Ker}(A^T A) = \text{Ker}(A)$ .*

*Demonstração.* Seja  $x \in \text{Ker}(A)$ , então  $A^T A x = A^T 0 = 0$ . Portanto,  $x \in \text{Ker}(A^T A)$ .

Agora, seja  $x \in \text{Ker}(A^T A)$ , então  $A^T A x = 0$ . Multiplicando por  $x^T$  em ambos os lados, temos que

$$\|Ax\| = 0.$$

Portanto,  $Ax = 0$  e assim  $x \in \text{Ker}(A)$ . Concluimos então que  $\text{Ker}(A^T A) = \text{Ker}(A)$ .  $\square$

**LEMA 0.2.** *Seja  $A \in \mathbb{R}^{m \times n}$ , então  $A^T A$  possui autovalores não-negativos.*

*Demonstração.* Seja  $v$  um autovetor associado a  $\lambda$  da matriz  $A^T A$ , então

$$A^T A v = \lambda v \rightarrow v^T A^T A v = \lambda v^T v.$$

Como  $A^T A$  é uma matriz semi definida positiva, temos que

$$\lambda v^T v \geq 0.$$

Além disso, como  $v$  é um autovetor,  $v^T v > 0$ , portanto,

$$\lambda \geq 0.$$

$\square$

Vamos agora provar o SVD. Seja  $A \in \mathbb{R}^{m \times n}$  uma matriz qualquer e suponha que  $m \geq n$ . Seja a matriz  $A^T A \in \mathbb{R}^{n \times n}$  e sejam  $x_1, \dots, x_n$  autovetores ortonormais e  $\lambda_1, \dots, \lambda_n$  os seus respectivos autovalores. Vamos ordenar os autovalores de forma que  $\lambda_1 \geq \dots \geq \lambda_n$ . E seja  $r$  tal que

$$\lambda_1 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_n.$$

Defina agora os vetores

$$q_i = \frac{1}{\sqrt{\lambda_i}} A x_i, \quad \text{para } i \leq r,$$

e chame de  $\sigma_i = \sqrt{\lambda_i}$ , para todo  $i = 1, \dots, n$ .

Observe que  $q_i^T q_j = 0$  para todo  $i \neq j$  e  $q_i^T q_i = 1$ . Portanto, vamos completar  $\{q_1, \dots, q_r\}$  de forma a obter uma base  $\{q_1, \dots, q_r, q_{r+1}, \dots, q_m\}$  de  $\mathbb{R}^m$ . Sejam agora as matrizes

$$U = \begin{pmatrix} | & & | \\ q_1 & \dots & q_m \\ | & & | \end{pmatrix}, \quad V = \begin{pmatrix} | & & | \\ x_1 & \dots & x_n \\ | & & | \end{pmatrix}.$$

Note que  $x_j \in \text{Ker}(A^T A)$  para  $j > r$ , pois o autovalor associado a  $x_j$  é 0. Pelo Lema 0.1,  $Ax_j = 0$ . Portanto,

$$(U^T A V)_{ij} = q_i^T A x_j = \begin{cases} \frac{1}{\sigma_i} x_i^T A^T A x_j & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases} = \begin{cases} \sigma_i \delta_{ij} & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases},$$

pois

$$\frac{1}{\sigma_i} x_i^T A^T A x_j = \frac{\lambda_j}{\sigma_i} x_i^T x_j = \sigma_i \delta_{ij}.$$

Portanto,  $U^T A V$  é dada por

$$\begin{matrix} & \overbrace{\hspace{1cm}}^n \\ \text{n} \left\{ \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n \\ 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 \end{bmatrix} \right\} \begin{matrix} \\ \\ \\ \\ \end{matrix} \end{matrix} \begin{matrix} \\ \\ \\ \\ \end{matrix} \left. \vphantom{\begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n \\ 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 \end{bmatrix}} \right\} \begin{matrix} \\ \\ \\ \\ \end{matrix} \begin{matrix} \\ \\ \\ \\ \end{matrix} \end{matrix}$$

Denotando por  $\Sigma$  a matriz acima, temos que

$$A = U\Sigma V^T$$

Seja agora  $m < n$ . Considere a matriz simétrica  $AA^T$ . Do mesmo modo que a anterior, temos que seus autovalores são todos não negativos. Sejam  $v_1, \dots, v_m$  os autovalores ortonormais associados a  $\lambda_1, \dots, \lambda_m$  autovalores. Ordene  $\lambda_1 \geq \dots \geq \lambda_m$ . Denote por  $\sigma_i = \sqrt{\lambda_i}$  para todo  $i = 1, \dots, m$ . Seja  $r$  tal que

$$\lambda_1 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = \lambda_m.$$

Para  $i = 1, \dots, r$ , denote por

$$q_i = \frac{1}{\sigma_i} A^T v_i.$$

Note que os  $q_i$ 's são ortonormais. Completando a base e utilizando o processo de ortogonalização de Gram-Schmidt, temos uma base  $\{q_1, \dots, q_r, q_{r+1}, \dots, q_n\}$  ortonormal de  $\mathbb{R}^n$ . Sejam agora as matrizes

$$U = \begin{pmatrix} | & & | \\ v_1 & \dots & v_m \\ | & & | \end{pmatrix}, \quad V = \begin{pmatrix} | & & | \\ q_1 & \dots & q_n \\ | & & | \end{pmatrix}.$$

Além disso, de modo análogo ao Lema 0.1, temos que  $\text{Ker}(AA^T) = \text{Ker}(A^T)$ , basta substituir  $A$  por  $A^T$ . Portanto,

$$(U^T AV)_{ij} = v_i^T A q_j = \begin{cases} \frac{1}{\sigma_i} v_i^T A A^T v_j & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases} = \begin{cases} \sigma_j \delta_{ij} & \text{se } j \leq r \\ 0 & \text{se } j > r \end{cases},$$

pois  $v_i \in \text{Ker}(A^T)$  e

$$\frac{1}{\sigma_j} v_i^T A A^T v_j = \frac{\lambda_i}{\sigma_j} v_i^T v_j = \sigma_j \delta_{ij}.$$

Portanto, a matriz  $U^T AV$  é dada por

$$\begin{matrix} & \overbrace{\hspace{1.5cm}}^m & \overbrace{\hspace{1.5cm}}^{n-m} \\ \text{m} \left\{ \begin{bmatrix} \sigma_1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & 0 & \dots & 0 \\ 0 & 0 & \dots & \sigma_m & 0 & \dots & 0 \end{bmatrix} \right. \end{matrix}$$

□

*Solução.* (Exercício 2)

Suponha  $m < n$ , então

$$\begin{aligned} Ax &= U\Sigma V^T = \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & 0 \\ & & \ddots & 0 \\ & & & \sigma_m & 0 \end{pmatrix} \begin{pmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_n^T & - \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \\ &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 v_1^T x \\ \vdots \\ \sigma_m v_m^T x \end{pmatrix} \end{aligned}$$

Seja agora  $x = v_i$ , então

$$\begin{aligned}
 Av_i &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 v_1^T v_i \\ \vdots \\ \sigma_m v_m^T v_i \end{pmatrix} \\
 &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ \vdots \\ \sigma_i \\ 0 \\ \vdots \\ 0 \end{pmatrix} \\
 &= \begin{pmatrix} \sigma_i u_{i1} \\ \sigma_i u_{i2} \\ \vdots \\ \sigma_i u_{ii} \\ \vdots \\ \sigma_i u_{im} \end{pmatrix} = \sigma_i u_i
 \end{aligned}$$

Já para  $A^T u_i$ , temos que

$$\begin{aligned}
 A^T x &= V \Sigma^T U^T = \begin{pmatrix} | & & | \\ v_1 & \dots & v_n \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ 0 & \dots & 0 & \sigma_m \\ & & & 0 \end{pmatrix} \begin{pmatrix} - & u_1^T & - \\ & \vdots & \\ - & u_m^T & - \end{pmatrix} \begin{pmatrix} x_1 \\ \vdots \\ x_m \end{pmatrix} \\
 &= \begin{pmatrix} | & & | \\ v_1 & \dots & v_n \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 u_1^T x \\ \vdots \\ \sigma_m u_m^T x \\ 0 \\ \vdots \\ 0 \end{pmatrix}
 \end{aligned}$$

Portanto, para  $x = u_i$

$$A^T u_i = \sigma_i v_i.$$

Para calcular os valores de  $\sigma_i$ ,  $u_i$  e  $v_i$ ,

$$A^T A v_i = \sigma_i A^T u_i = \sigma_i^2 v_i.$$

Logo,  $v_i$  é o autovetor de  $A^T A$  associado ao autovalor  $\sigma_i^2$  da matriz  $A^T A$ . E

$$A A^T u_i = \sigma_i A v_i = \sigma_i^2 u_i.$$

Logo,  $u_i$  é o autovetor de  $A A^T$  associado ao autovalor  $\sigma_i^2$  da matriz  $A A^T$ . Isto pode ser visto também através da demonstração do SVD pelo exercício 1.  $\square$

*Solução.* (Exercício 3)

(a) De fato, como  $A = U \Sigma V^T$ , e como  $U, V^T$  são matrizes ortogonais, temos que  $\text{posto}(U \Sigma V^T) =$

posto( $\Sigma$ ). E como  $\text{posto}(\Sigma) = r$ , já que

$$\Sigma = \begin{pmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \\ & & & & & & 0 \\ & & & & & & & 0 \\ 0 & & & & & & & & 0 \end{pmatrix}$$

$$\Rightarrow \text{posto}(A) = \text{posto}(\Sigma) = r.$$

(b) Seja  $x \in \mathbb{R}^n$ , então

$$x = b_1 v_1 + \dots b_n v_n,$$

onde  $v_1, \dots, v_n$  são os vetores singulares à direita da decomposição SVD da matriz A. Então, pelo exercício 2

$$\begin{aligned} Ax &= A(b_1 v_1 + \dots b_n v_n) = b_1 \sigma_1 u_1 + \dots b_r \sigma_r u_r \\ \Rightarrow \text{Im}(A) &\in \text{span}\{u_1, \dots, u_r\} \end{aligned}$$

Seja  $x \in \text{span}\{u_1, \dots, u_r\}$ . Pelo exercício 2,  $u_i = \frac{1}{\sigma_i} A v_i$ , portanto,  $x \in \text{Im}(A)$ .

$$\text{Im}(A) = \text{span}\{u_1, \dots, u_r\}.$$

(c) Seja  $x \in \text{Ker}(A)$ . Como  $x \in \mathbb{R}^n$ ,  $x = b_1 v_1 + \dots b_n v_n$ .

$$A(b_1 v_1 + \dots + b_n v_n) = 0 \Rightarrow b_1 \sigma_1 u_1 + \dots + b_r \sigma_r u_r = 0$$

Como os vetores  $u_1, \dots, u_m$  formam uma base para  $\mathbb{R}^m$  e  $\sigma_1, \dots, \sigma_r \neq 0$ , temos que

$$b_1 = \dots = b_r = 0.$$

Portanto,  $x \in \text{span}\{v_{r+1}, \dots, v_n\}$ . Do mesmo modo, temos que  $A v_i = \sigma_i u_i$ . Se  $i > r$ , então  $\sigma_i = 0$ .

$$A v_i = 0 \Rightarrow v_i \in \text{Ker}(A) \Rightarrow \text{Ker}(A) = \text{span}\{v_{r+1}, \dots, v_n\}.$$

(d) De fato, note que pelos exercícios anteriores, se  $m < n$ , então

$$\begin{aligned} A &= U \Sigma V^T = \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & 0 \\ & & \ddots & 0 \\ & & & \sigma_m & 0 \end{pmatrix} \begin{pmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_n^T & - \end{pmatrix} \\ &= \begin{pmatrix} | & & | \\ u_1 & \dots & u_m \\ | & & | \end{pmatrix} \begin{pmatrix} \sigma_1 v_1^T x \\ \vdots \\ \sigma_m v_m^T x \end{pmatrix} \\ &= \sum_{i=1}^m \sigma_i u_i v_i^T = \sum_{i=1}^r \sigma_i u_i v_i^T \end{aligned}$$

□

*Solução.* (Exercício 4)

- (a) Esta é a norma de Frobenius de uma matriz  $A$ , dada por

$$\|A\|_F^2 = \text{tr}(AA^T),$$

onde  $\text{tr}$  é o operador traço. Além disso, se  $U$  for uma matriz ortogonal, então

$$\|UA\|_F^2 = \text{tr}(UAA^T U^T) = \text{tr}(AA^T U^T U) = \text{tr}(AA^T) = \|A\|_F^2.$$

Ainda mais, isto vale para multiplicação à direita, ou seja

$$\|AU\|_F^2 = \text{tr}(AUU^T A^T) = \text{tr}(AA^T) = \|A\|_F^2.$$

Portanto,

$$\|A\|_F^2 = \|U\Sigma V^T\|_F^2 = \|\Sigma\|_F^2 = \sigma_1^2 + \dots + \sigma_p^2,$$

$$p = \min\{m, n\}.$$

- (b) Note que se  $x$  é um vetor cuja norma é igual a um e  $V$  é uma matriz ortogonal, então  $\|Vx\| = \|x\| = 1$ . Portanto,

$$\begin{aligned} \|A\|_2 &= \sup_{\|x\|=1} \|Ax\| = \sup_{\|x\|=1} \|U\Sigma V^T x\| \\ &= \sup_{\|x\|=1} \|\Sigma V^T x\| = \sup_{\|V^T x\|=1} \|\Sigma V^T x\| = \sup_{\|y\|=1} \|\Sigma y\| \\ &= \|\Sigma\|_2 \end{aligned}$$

Suponha que  $m < n$ , então

$$\Sigma = \begin{pmatrix} \sigma_1 & & & 0 \\ & \sigma_2 & & 0 \\ & & \ddots & 0 \\ & & & \sigma_m & 0 \end{pmatrix}$$

Logo,

$$\|\Sigma\|_2 = \sup_{\|x\|=1} \|\Sigma x\| = \sup_{\|x\|=1} \left| \sqrt{\sigma_1^2 x_1^2 + \dots + \sigma_m^2 x_m^2} \right| \leq \sup_{\|x\|=1} \sigma_1 \|x\| = \sigma_1,$$

já que  $\sigma_1 > 0$ . Agora seja  $x = (1, 0, \dots, 0) \in \mathbb{R}^n$ . Então,  $\|x\|_2 = 1$ . Portanto,  $\|\Sigma x\|_2 = \sigma_1$ . Ou seja,  $\|\Sigma\|_2 \geq \sigma_1$ .

$$\|A\|_2 = \|\Sigma\|_F = \sigma_1.$$

de modo análogo temos que para  $m \geq n$ .

- (c) Seja  $m \geq n$ . Então,

$$\Sigma = \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \\ 0 & 0 & \dots & 0 \end{pmatrix}$$

Assim,

$$\begin{aligned} \min_{x \neq 0} \frac{\|Ax\|}{\|x\|} &= \min_{x \neq 0} \|\Sigma x\| / \|x\| \\ &= \min_{x \neq 0} \frac{\left| \sqrt{\sigma_1^2 x_1^2 + \dots + \sigma_n^2 x_n^2} \right|}{\|x\|} \\ &\geq \sigma_n \min_{x \neq 0} \frac{\|x\|}{\|x\|} = \sigma_n. \end{aligned}$$

Por outro lado, seja  $x = (0, 0, \dots, 0, 1) \in \mathbb{R}^m$ , então

$$\begin{aligned} \min_{y \neq 0} \frac{\|Ay\|_2}{\|y\|_2} &\leq \frac{\|\Sigma x\|_2}{\|x\|_2} = \sigma_n. \\ \Rightarrow \min_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2} &= \sigma_n. \end{aligned}$$

□

*Solução.* (Exercício 5)

Note que  $\|A - A_k\|_2 = \sigma_{k+1}$ , pois

$$\|A - A_k\|_2 = \left\| \sum_{j=k+1}^n \sigma_j u_j v_j^T \right\| = \sigma_{k+1}$$

pelo exercício 4-b. Portanto, resta mostrar que

$$\min_{\text{posto}(B)=k} \|A - B\|_2 = \|A - A_k\|.$$

Como  $\text{posto}(A_k) = k$ , já que  $k < r$ , temos que

$$\min_{\text{posto}(B)=k} \|A - B\|_2 \leq \|A - A_k\|.$$

Resta mostrar que

$$\min_{\text{posto}(B)=k} \|A - B\|_2 \geq \|A - A_k\|.$$

Seja  $U\Sigma V^T$  a decomposição SVD da matriz  $A$ . Seja  $B$  uma matriz de posto igual a  $k$ . Como  $k < r$ , temos pelo teorema do núcleo e da imagem que  $\dim(\text{Ker}(B)) = n - k$ . Além disso, restrinja a matriz  $V$  para  $V_k$ , sendo  $V_k$  a matriz das primeiras  $k+1$  colunas de  $V$ , portanto,  $\dim(V_k) = k+1$ . Logo,

$$\dim(\text{Ker}(B)) + \dim(V_k) = n - k + k + 1 = n + 1.$$

Como a soma das dimensões é maior que  $n$  e ambos espaços estão contidos em  $\mathbb{R}^n$ , temos que

$$\text{Ker}(B) \cap V_k \neq \emptyset.$$

Tome  $x \in \text{Ker}(B) \cap V_k$ , tal que  $\|x\|_2 = 1$ . Então

$$\|A - B\|_2 \geq \|Ax - Bx\|_2 = \|A_{k+1}x\|_2.$$

Como  $x \in V_k$ ,  $x = c_1 v_1 + \dots + c_{k+1} v_{k+1}$ , então

$$\begin{aligned} A_{k+1}x &= \sum_{i=1}^{k+1} \sigma_i u_i v_i^T x = \sum_{i=1}^{k+1} \sigma_i u_i v_i^T (c_1 v_1 + \dots + c_{k+1} v_{k+1}) \\ &= \sum_{i=1}^{k+1} \sigma_i c_i u_i. \end{aligned}$$

Utilizando o resultado acima, temos que

$$\|A_{k+1}x\|_2^2 = \left\| \sum_{i=1}^{k+1} \sigma_i c_i u_i \right\|_2^2 \geq \sigma_{k+1}^2 \left\| \sum_{i=1}^{k+1} c_i u_i \right\|_2^2.$$

E note que

$$1 = \|x\|_2^2 = \left\langle \sum_i c_i v_i, \sum_j c_j v_j \right\rangle = \sum_{i=1}^{k+1} c_i^2.$$

Mas como os vetores  $u_1, \dots, u_{k+1}$  são ortonormais, temos que

$$\left\| \sum_{i=1}^{k+1} c_i u_i \right\|_2^2 = \left\langle \sum_i c_i u_i, \sum_j c_j u_j \right\rangle = \sum_{i=1}^{k+1} c_i^2.$$

Portanto, juntando os resultados acima, temos que

$$\|A - B\|_2 \geq \sigma_{k+1}$$

Assim, obtemos o resultado desejado.

$$\min_{\text{posto}(B)=k} \|A - B\|_2 = \|A - A_k\|_2 = \sigma_{k+1}.$$

□

*Solução.* (Exercício 6)

Considere a SVD de  $A \in \mathbb{R}^{m \times n}$  dada no Exercício 1. Portanto, pelo exercício 4, queremos mostrar que

$$\sigma_1 = \max_{\substack{y \in \mathbb{R}^m \\ x \in \mathbb{R}^n}} \frac{y^T A x}{\|x\|_2 \|y\|_2}.$$

Suponha que a matriz  $A$  tenha posto maior ou igual a 1, então  $\sigma_1 \neq 0$ .

Agora, considere  $x$  como o autovetor unitário associado a  $\lambda_1$  da matriz  $A^T A$ . Seja agora  $y = Ax/\sigma_1$ , onde  $\sigma_1 = \sqrt{\lambda_1}$ . Então

$$\|y\|_2^2 = y^T y = \frac{1}{\sigma_1^2} x^T A^T A x = 1.$$

Logo,

$$y^T A x = \frac{x^T A^T A x}{\sigma_1} = \sigma_1.$$

Acabamos de mostrar que

$$\max_{\substack{y \in \mathbb{R}^m \\ x \in \mathbb{R}^n}} \frac{y^T A x}{\|x\|_2 \|y\|_2} \geq \sigma_1.$$

Vamos mostrar que vale a outra desigualdade agora. Seja  $r = \text{posto}(A)$ , então

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Como os vetores  $v_1, \dots, v_n$  formam uma base de  $\mathbb{R}^n$  e  $u_1, \dots, u_m$  de  $\mathbb{R}^m$ , para todo  $x \in \mathbb{R}^n$  e  $y \in \mathbb{R}^m$ ,

$$x = d_1 v_1 + \dots + d_n v_n, \quad y = c_1 u_1 + \dots + c_m u_m.$$

Logo,

$$\begin{aligned} \frac{y^T A x}{\|y\|_2 \|x\|_2} &= \frac{(\sum_{i=1}^m c_i u_i)^T (\sum_{i=1}^r \sigma_i u_i v_i^T) (\sum_{i=1}^n d_i v_i)}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \\ &= \frac{(\sum_{i=1}^m c_i u_i)^T (\sum_{i=1}^r \sigma_i u_i d_i)}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \\ &= \frac{\sum_{i=1}^r \sigma_i c_i d_i}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \\ &\leq \sigma_1 \frac{\sum_{i=1}^r c_i d_i}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \end{aligned} \tag{1}$$



Como  $r \leq m, n$ , considere os vetores

$$c' = (c_1, \dots, c_r), \quad d' = (d_1, \dots, d_r).$$

Além disso, considere  $c = (c_1, \dots, c_m)$  e  $d = (d_1, \dots, d_n)$ . Então

$$\sum_{i=1}^r c_i^2 \leq \sum_{i=1}^m c_i^2 \Rightarrow \frac{1}{(\sum_{i=1}^r c_i^2)^{\frac{1}{2}}} \geq \frac{1}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}}}.$$

De modo análogo para  $d$  e  $d'$

$$\frac{1}{(\sum_{i=1}^r d_i^2)^{\frac{1}{2}}} \geq \frac{1}{(\sum_{i=1}^n d_i^2)^{\frac{1}{2}}}.$$

E pela desigualdade de Cauchy-Schwarz,  $|\langle c, d \rangle| \leq \|c\|_2 \|d\|_2$ . Portanto,

$$\frac{|\langle c, d \rangle|}{\|c\|_2 \|d\|_2} \leq 1.$$

Substituindo os valores e desigualdades acima na Equação (1), temos que

$$\sigma_1 \frac{\sum_{i=1}^r c_i d_i}{(\sum_{i=1}^m c_i^2)^{\frac{1}{2}} (\sum_{i=1}^n d_i^2)^{\frac{1}{2}}} \leq \sigma_1 \frac{\sum_{i=1}^r c_i d_i}{(\sum_{i=1}^r c_i^2)^{\frac{1}{2}} (\sum_{i=1}^r d_i^2)^{\frac{1}{2}}} \leq \sigma_1.$$

Como isto vale para qualquer  $x$  e  $y$ ,

$$\sigma_1 = \sigma_{\max}(A) = \max_{\substack{y \in \mathbb{R}^m \\ x \in \mathbb{R}^n}} \frac{y^T A x}{\|x\|_2 \|y\|_2}.$$

□

*Solução.* (Exercício 7)

Vamos usar SVD para provar. Seja  $A \in \mathbb{R}^{m \times n}$  uma matriz qualquer, e considere a SVD de  $A$  dada no exercício 1. Suponha que  $\text{posto}(A) = r$ , sendo que  $r \leq \min m, n$ . Suponha que  $n \leq m$ , a demonstração a seguir pode ser usada analogamente para o caso  $n > m$ .

Temos

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Seja agora a sequência de matrizes  $B_k$ , onde

$$B_k = \sum_{i=1}^n \left( \sigma_i + \frac{1}{k} \right) u_i v_i^T.$$

Observe que as matrizes  $B_k$  tem posto completo, já que  $B_k = U \Sigma_k V^T$ , onde  $U, V$  são matrizes ortogonais e  $\Sigma_k$  possui posto cheio, já que as colunas de  $\Sigma_k$  são linearmente independentes.

$$\Sigma_k = \begin{pmatrix} \sigma_1 + \frac{1}{k} & 0 & \cdots & 0 \\ 0 & \sigma_2 + \frac{1}{k} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n + \frac{1}{k} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix}.$$

Além disso, note que  $A - B_k = U(\Sigma - \Sigma_k)V^T$ , e portanto,

$$\|A - B_k\|_2 = \|U(\Sigma - \Sigma_k)V^T\|_2 = \|\Sigma - \Sigma_k\|,$$

já que  $U$  e  $V$  são matrizes ortogonais. Além disso, note que

$$\Sigma - \Sigma_k = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix} - \begin{pmatrix} \sigma_1 + \frac{1}{k} & 0 & \cdots & 0 \\ 0 & \sigma_2 + \frac{1}{k} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n + \frac{1}{k} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix} = \begin{pmatrix} \frac{1}{k} & 0 & \cdots & 0 \\ 0 & \frac{1}{k} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \frac{1}{k} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \end{pmatrix}.$$

Sabemos que o valor singular  $\sigma_1$  de uma matrix  $A$  é a raiz quadrada do maior autovalor da matriz  $A^T A$ . Neste caso, o valor singular  $\sigma_1$  da matriz  $\Sigma - \Sigma_k$  é  $\frac{1}{k}$  já que o maior autovalor da matriz  $(\Sigma - \Sigma_k)^T(\Sigma - \Sigma_k)$  é  $\frac{1}{k^2}$ . Pelo exercício 4-b, temos que

$$\|\Sigma - \Sigma_k\|_2 = \sigma_1.$$

Portanto,

$$\|A - B_k\|_2 = \|\Sigma - \Sigma_k\|_2 = \sigma_1 = \frac{1}{k}.$$

Ou seja, para todo  $\epsilon > 0$ , existe  $k_0$  tal que para todo  $k > k_0$ ,

$$\|A - B_k\|_2 < \epsilon.$$

Assim, mostramos que qualquer matriz em  $\mathbb{R}^{m \times n}$  é o limite de uma sequência de matrizes de posto completo.  $\square$

*Solução.* (Exercício 8)

Seja  $\Omega = \{x_1, \dots, x_m\} \subset \mathbb{R}^n$  um conjunto de dados e  $k \in (1, m)$  um número natural. O Algoritmo de Lloyd ( $k$ -médias) para clusterização consiste em achar centros, ou pontos, de modo que o conjunto de treinamento possa ser separado em  $k$  partições, todas disjuntas. Ou seja, o objetivo é encontrar uma partição ótima

$$S = \{S_1, \dots, S_m\}$$

de  $\Omega$ , isto é, encontrar  $S_i$ , chamados de *clusters*, tais que

$$S_i \cap S_j = \emptyset, \quad i \neq j$$

$$\bigcup_{i=1}^k S_i = \Omega.$$

Em termos de minimização, queremos resolver o seguinte problema de minimização.

$$\min_{\substack{S \\ \text{partição de } \Omega}} \sum_{i=1}^k \sum_{x_j \in S_i} \|x_j - \mu_i\|_2^2, \quad \text{onde } \mu_i = \frac{1}{|S_i|} \sum_{x_j \in S_i} x_j.$$

Então, o Algoritmo de Lloyd é dado a seguir.  $\square$

*Solução.* (Exercício 9)

Seja um banco de dados  $\{I_1, \dots, I_m\}$ , onde cada  $I_i$  é uma matriz de imagens em escala cinza. Temos  $m$  imagens, de tamanho  $n \times n$ , divididas em  $p$  classes, onde cada classe representa a face de uma pessoa. Para cada matriz  $I_j$ , denote por  $\Phi_j$  o vetor de concatenação das matrizes. Seja  $A$  a matriz abaixo.

$$A = \begin{pmatrix} | & | & \cdots & | \\ \Phi_1 & \Phi_2 & \cdots & \Phi_m \\ | & | & & | \end{pmatrix} \in \mathbb{R}^{n^2 \times m}.$$

Para classificar uma nova imagem  $I_{new} = \Phi_{new}$ , calculamos a projeção ortogonal no espaço gerado pelas colunas da matriz  $A$ , assim podemos dizer de qual vetor coluna da matriz  $A$ , a imagem  $\Phi_{new}$  está mais perto, e esta será a sua classe. Portanto, o procedimento é dado no Algoritmo abaixo.  $\square$

---

**Algoritmo 1** Algoritmo de Lloyd

---

- 1: Escolha  $k$  pontos  $m_1^{(1)}, \dots, m_k^{(1)}$  em  $\Omega$ , os quais serão usados como "médias iniciais". Defina  $t = 1$ .
- 2: Para cada  $j = 1, \dots, m$ , encontre

$$i \in \operatorname{argmin}_{l=1, \dots, k} \|x_j - m_l^{(t)}\|$$

- e associe  $x_j$  ao cluster  $S_i$ .
- 3: Se  $t > 1$  e  $S^t = S^{t-1}$ , pare.
  - 4: (Atualização das médias) Para cada  $i = 1, \dots, k$ , defina

$$m_i^{t+1} = \frac{1}{|S_i|} \sum_{x_j \in S_i^{(t)}} x_j$$

- 5: Defina  $t = t + 1$  e volte para o passo 2.
- 

---

**Algoritmo 2** Auto-faces para reconhecimento facial

---

- 1: Calcule a projeção ortogonal  $\hat{\Phi}_{new}$  de  $\Phi_{new}$  sobre o subespaço gerado por  $\Phi_1, \dots, \Phi_m$ .

$$\hat{\Phi}_{new} = A(A^T A)^{-1} \Phi_{new}$$

- 2: Calcule

$$j = \operatorname{argmin}_{i=1, \dots, m} \|\hat{\Phi}_{new} - \Phi_i\|$$

- 3: Dizemos então que a face em  $I_{new}$  é a face da pessoa em  $I_j$ .
-